Samsung Data Challenge 2018

교통사망사고정보 Data Completion

Timmy YeongTaek Oh Samsung Data Challenge 2018



- Problem & Data Overview
- Data Split & Augmentation
- Model Structure
- Result

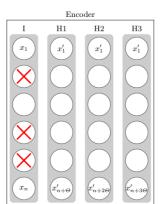
Problem & Data Overview

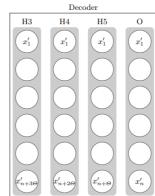
- Problem Overview (Test Data 기준)
 - Imputation Missing Values based on other values
 - Missing Variables can be any variable in test data (Figure 1)
 - -> Self Data Completion
- How to Solve?
 - AutoEncoder with Missing Value
 - ➤ Baseline on Multiple Imputation using Denoising AutoEncoder (MIDA)

(Figure 2)

주야	요일	사망자 수	사상자 수	중상자 수) 경상자 수	부상신 고자수	발생지 시도	발생지 시군구	사고유 형_대분 류	사고유 형_중분 류	법규위 반	도로형 태_대분 류	도로형 태	당사자 종별_1 당_대분 류	당사자 종별_2 당_대분 류
야간	금			C)	0	경기	화성시	차대차	측면충 돌	중앙선 침범	단일로	기타단 일로	승용차	승합차
야간	화	1	1	C	0	0	대구	북구				단일로	기타단 일로	승용차	화물차
주간		1	1	C	0	0	서울	동작구			신호위 반	교차로	교차로 내	화물차	원동기 장치자 전거
	일			C	0	0	전북	고창군	차대사 람	기타	부당한 회전	교차로	교차로 내		보행자

Figure 1. Sample of Test Data





Problem & Data Overview

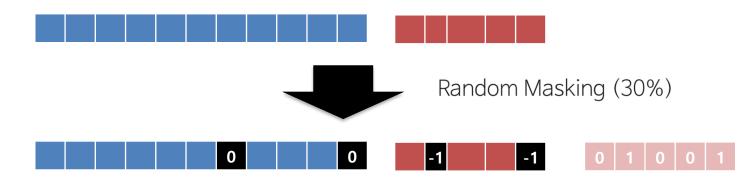
- # of data: Train 25037, Test:?
 - Train Data: 12.01 ~ 17.06 기간의 교통사망사고정보 데이터
 - Test Data: 17.07 이후의 교통사망사고정보 데이터 (Not provided)
- # of Variables : Train(27) ⊃ Test(16)
 - Categorical Variables : 11
 - Numerical Variables: 5
- Metric for Variables
 - Categorical Variable : $C \times \sum_{i=1}^{k_2} \delta_{c_i d_i}$
 - Categorical Loss: Categorical Cross Entropy
 - Numerical Variable : $B \times \sum_{i=1}^{k_1} \exp\left\{-\left(\frac{n_i m_i}{s_j}\right)^2\right\}$
 - Numerical Loss: Mean Squared Error

	-
발생년	사고유형
발생년월일시	법규위반_대 분류
발생분	법규위반
주야	도로형태_대 분류
요일	도로형태
사망자수	당사자종별_1 당_대분류
사상자수	당사자종별_1 당
중상자수	당사자종별_2 당_대분류
경상자수	당사자종별_2 당
부상신고자수	발생위치X_U TMK
발생지시도	발생위치Y_U TMK
발생지시군구	경도
사고유형_대 분류	위도
사고유형_중 분류	

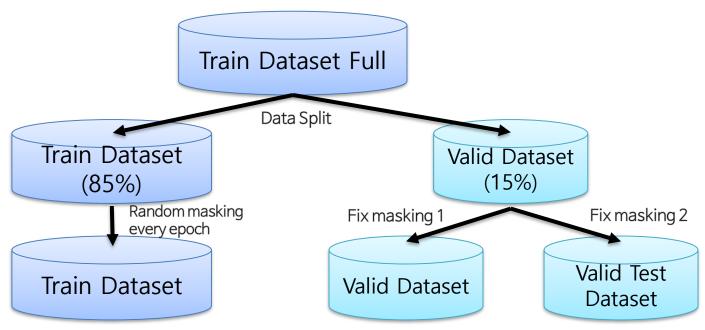
Table 1. Variables in data

Data Split & Augmentation

- Training Set / Validation Set (85% / 15%)
 - 1. 15% Random Sampling from Training Data (Time Shuffled) * 2
 - 2. 15% Latest Data in Training Data (Time Not Shuffled)
- Masking missing values
 - Categorical variables: mask '0' for missing categorical value
 - Numerical variables: mask '-1' value on missing and create missing table $(n \times 5)$



Data Split & Augmentation





- Random masking on Training Data on every step
 - gives data augmentation effects
- Fixed masking on Validation Data for early stopping
- Different Fixed masking on Validation Data for parameter tuning (self-test)
 - to prevent overfitting on validation set

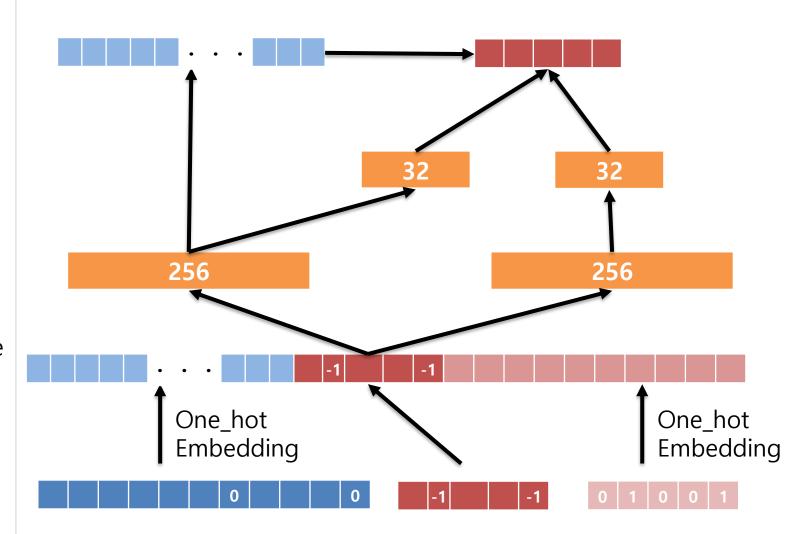
Model Structure

Projection Layer

Hidden Layer2

Hidden Layer

Concatenate Embedding Layer



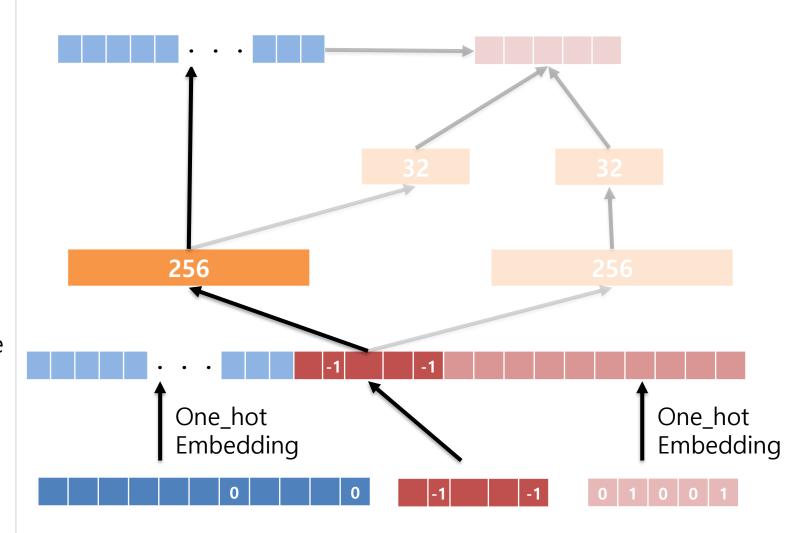
Model Structure (Categorical Label)

Projection Layer

Hidden Layer2

Hidden Layer

Concatenate Embedding Layer



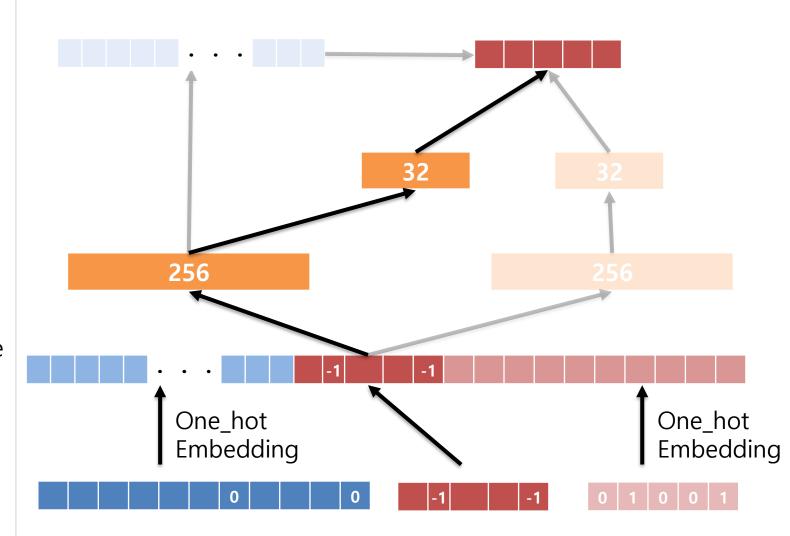
Model Structure (Numerical Label Path1)

Projection Layer

Hidden Layer2

Hidden Layer

Concatenate Embedding Layer



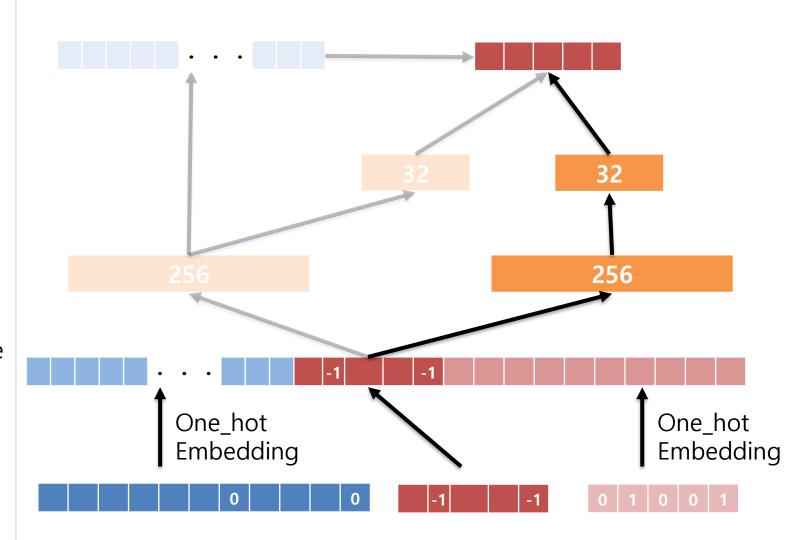
Model Structure (Numerical Label Path2)

Projection Layer

Hidden Layer2

Hidden Layer

Concatenate Embedding Layer



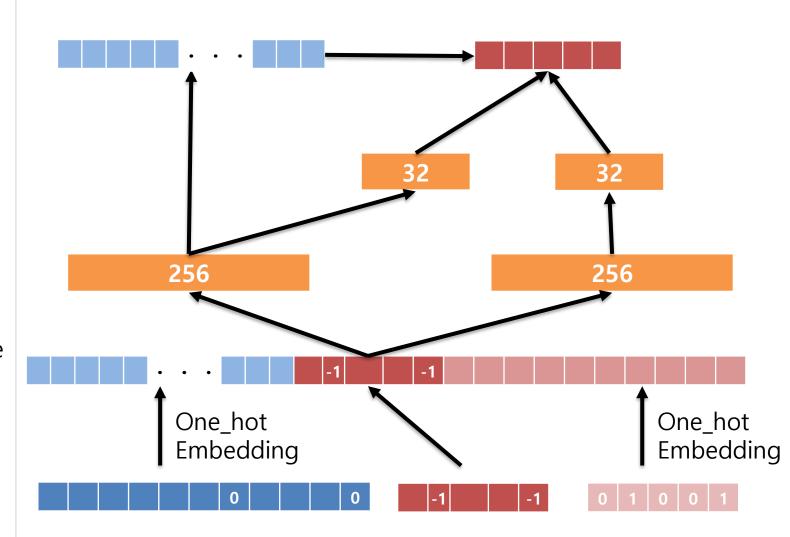
Model Structure (Numerical Label Path3)

Projection Layer

Hidden Layer2

Hidden Layer

Concatenate Embedding Layer



Result on Validation Test

- Total Loss = Categorical Loss + 2* Numerical Loss
 - ✓ Categorical Loss : Categorical Cross Entropy per categorical variable
 - ✓ Numerical Loss : Average 3 Path MSE on Continuous Label
 - Categorical score : $C \times \sum_{i=1}^{k_2} \delta_{c_i d_i}$
 - Numerical score : $B \times \sum_{i=1}^{k_1} \exp\left\{-\left(\frac{n_i m_i}{s_j}\right)^2\right\}$
- 3 different validation-data split Models
 - ✓ 2 Random Shuffle split
 - ✓ 1 Latest Split
- Final Model is ensemble 3 models by averaging scores

Model No.	Split Type(seed)	Category Score	Numerical Score	Total Score
1	Random (1000)	0.6256	0.9407	1.5663
2	Random (2000)	0.6330	0.9391	1.5721
3	Latest	0.5981	0.9414	1.5396

Thank you